Türkiye Yüzyılı Maarif Modeli Ekseninde Yapılandırılmış Eğitim İçeriği Üretiminde Yapay Zeka Tabanlı Sistemler: Kapsamlı Bir Araştırma ve Mimari Öneri Raporu

1. Giriş: Eğitimde Dijital Dönüşüm ve Otomatik Değerlendirme İhtiyacı

Yirmi birinci yüzyılın ilk çeyreğinde eğitim paradigmalarında yaşanan köklü değişimler, öğretim süreçlerinin merkezine salt bilgi aktarımından ziyade beceri edinimini ve bütüncül gelişimi yerleştirmiştir. Geleneksel eğitim modelleri, öğrencinin bilgiyi ne kadar hatırladığını ölçmeye odaklanırken, modern pedagojik yaklaşımlar öğrencinin bilgiyi nasıl işlediğine, analiz ettiğine ve yeni durumlara nasıl transfer ettiğine odaklanmaktadır. Bu bağlamda, Türkiye Cumhuriyeti Milli Eğitim Bakanlığı tarafından geliştirilen ve uygulamaya konulan "Türkiye Yüzyılı Maarif Modeli", eğitimin ontolojik ve epistemolojik temellerini yeniden tanımlayarak, öğrenciyi "yetkin ve erdemli insan" olarak yetiştirmeyi hedefleyen özgün bir tasarım olarak karşımıza çıkmaktadır. Bu model, sadece akademik başarıyı değil, aynı zamanda sosyal, duygusal, fiziksel ve ahlaki gelişimi de kapsayan bütüncül bir yaklaşımı benimsemektedir.[1]

Eğitimdeki bu yapısal dönüşüm, ölçme ve değerlendirme süreçlerinde de devrim niteliğinde değişiklikleri zorunlu kılmaktadır. Geleneksel çoktan seçmeli testler, üst düzey bilişsel becerilerin ve süreç odaklı yetkinliklerin ölçülmesinde yetersiz kalmaktadır. Buna karşılık, açık uçlu sorular, projeler ve performans görevleri, öğrencinin düşünme süreçlerini, argümantasyon yeteneğini ve yaratıcılığını ortaya çıkarmada çok daha etkilidir. Ancak, açık uçlu soruların üretimi ve değerlendirilmesi, eğitimciler için ciddi bir zaman ve emek maliyeti oluşturmaktadır. Ölçeklenebilirlik sorunu, nitelikli geri bildirim sağlama zorluğu ve değerlendirici öznelliği, bu tür ölçme araçlarının yaygınlaşmasının önündeki en büyük engellerdir.[2]

Yapay zeka (YZ) ve özellikle Büyük Dil Modelleri (LLM) alanındaki son gelişmeler, bu engellerin aşılması için benzersiz fırsatlar sunmaktadır. Doğal Dil İşleme (NLP) teknolojilerinin geldiği nokta, metin tabanlı eğitim materyallerinin otomatik olarak üretilmesini, analiz edilmesini ve değerlendirilmesini mümkün kılmaktadır. Ancak, jenerik LLM'lerin eğitim alanına doğrudan entegrasyonu, müfredat uyumsuzluğu, olgusal hatalar (halüsinasyon) ve pedagojik derinlik eksikliği gibi riskleri barındırmaktadır. Bu nedenle, eğitim teknolojileri literatüründe, müfredat standartlarına sıkı sıkıya bağlı, pedagojik geçerliliği yüksek ve belirli bir yapısal şablona sadık kalan "yapılandırılmış soru üretimi" yaklaşımları önem kazanmaktadır.[4]

Bu rapor, otomatik açık uçlu soru değerlendirme ve üretimi literatürünü, Türkiye Yüzyılı Maarif Modeli'nin gereksinimleri doğrultusunda derinlemesine analiz etmeyi amaçlamaktadır. Raporda, öğrenme çıktıları, süreç bileşenleri ve alan becerileri arasındaki hiyerarşik ilişkiler

incelenecek; farklı disiplinlerde tutarlı bir soru şablonunun korunmasını sağlayan model mimarileri değerlendirilecek; LLM'lerde bağlam içi öğrenme ve çok aşamalı prompt tekniklerinin etkinliği tartışılacak; ve müfredat uyumunu garanti altına alan ontoloji tabanlı hibrit yaklaşımlar detaylandırılacaktır. Ayrıca, üretilen soruların pedagojik geçerliliğinin denetlenmesi, RAG ve ince ayar yöntemlerinin karşılaştırılması ve disiplinler arası bir soru üretim motorunun tasarımı için gerekli olan veri seti ve etiketleme stratejileri ele alınacaktır.

2. Müfredat Hedefleri ve Değerlendirme Kriterleri ile Eşleşen Yapılandırılmış Soru Üretimi

Eğitimde otomasyonun temel amacı, öğretmenin yerini almak değil, öğretim tasarım sürecini veriye dayalı ve standartlara uygun hale getirerek öğretmeni desteklemektir. Bu bağlamda, otomatik soru üretimi (AQG - Automated Question Generation), rastgele metin üretiminden ziyade, belirli bir öğrenme hedefine ve değerlendirme kriterine (rubrik) hizmet eden, kısıtları belirlenmiş bir optimizasyon problemi olarak ele alınmalıdır.

2.1. Türkiye Yüzyılı Maarif Modeli'nde Müfredat Hiyerarşisi ve Soru Yapısı

Türkiye Yüzyılı Maarif Modeli, öğretim programlarını hiyerarşik ve bütüncül bir yapıda kurgulamıştır. Bu yapı, otomatik soru üretim sistemlerinin mimarisini doğrudan etkilemektedir. Modelin temel bileşenleri şunlardır:

1. **Öğrenme Çıktıları (Outcome):** Öğrencinin öğretim süreci sonunda kazanması beklenen bilgi, beceri ve değerlerin bütünüdür. Bu çıktılar, alan becerileri, kavramsal beceriler ve temel konuların ilişkilendirilmesiyle oluşturulur. Örneğin, 10. sınıf biyoloji dersinde "Canlıların yaşamına devam edebilmesi için enerjinin gerekliliğini sorgulayabilme" (BİY.10.1.1) bir öğrenme çıktısıdır.[1]
2. **Beceriler (Skills):** Müfredat, hem derse özgü "Alan Becerileri"ni (örneğin biyolojide bilimsel çıkarım yapma, deney tasarlama) hem de disiplinler üstü "Kavramsal Beceriler"i (eleştirel düşünme, problem çözme) kapsamaktadır.
3. **Süreç Bileşenleri (Components):** Beceri ediniminin gerçekleştiğini gösteren, gözlemlenebilir ve ölçülebilir adımlardır. Örneğin, "sorgulama" becerisinin süreç bileşenleri; merak etme, soru sorma, bilgi toplama ve değerlendirme basamaklarını içerebilir. Değerlendirme sorularının, bu süreç bileşenlerini tetikleyecek nitelikte olması gerekmektedir.[1]

Bu hiyerarşiye dayalı olarak, otomatik sistemlerin üretmesi gereken soru şablonu şu dört temel unsuru içermelidir:

- **Öğrenme Çıktısı (Outcome Metadata):** Sorunun hangi kazanıma hizmet ettiği.
- **Yönerge (Instruction):** Öğrenciye verilen bağlam, veri seti veya durum senaryosu.
- **Soru Metni (Question Stem):** Öğrencinin zihinsel sürecini başlatan ve yanıtı yönlendiren asıl soru.
- **Rubrik (Scoring Key):** Yanıtın değerlendirilmesinde kullanılacak kriterler ve puanlama anahtarı.

2.2. Literatürdeki Yapılandırılmış Üretim Yaklaşımları

Akademik literatürde, bu tür yapılandırılmış çıktıları elde etmek için çeşitli yaklaşımlar önerilmektedir. Geleneksel "seq2seq" modelleri, genellikle metinden soruya (text-to-question) dönüşüm yaparken yapısal tutarlılığı korumakta zorlanmaktadır. Ancak, son dönemde geliştirilen "Kontrollü Metin Üretimi" (Controlled Text Generation) teknikleri, LLM'lerin çıktılarını belirli bir şablona zorlamak için kullanılmaktadır.

Bir yaklaşım, **Şema Güdümlü Üretim (Schema-Guided Generation)** yöntemidir. Bu yöntemde, modelin çıktısı, katı bir JSON şeması veya XML yapısı ile sınırlandırılır. Model, sadece soru metnini değil, aynı zamanda sorunun zorluk seviyesini, bilişsel düzeyini (Bloom taksonomisine göre) ve ilgili rubrik maddelerini de yapılandırılmış veri formatında üretmeye zorlanır. Bu sayede, üretilen içeriğin eğitim yönetim sistemlerine (LMS) entegrasyonu kolaylaşır ve değerlendirme tutarlılığı artar.[5]

Diğer bir yaklaşım ise **Tersine Mühendislik (Reverse Engineering)** tabanlı üretimdir. Bu yöntemde, model önce ideal öğrenci yanıtını veya değerlendirme kriterlerini (rubrik) oluşturur, ardından bu yanıta veya kriterlere uygun soruyu türetir. Araştırmalar, rubrik odaklı soru üretiminin (rubric-to-question), soru odaklı rubrik üretiminden (question-to-rubric) daha yüksek pedagojik geçerliliğe sahip olduğunu göstermektedir. Çünkü rubrik, ölçülmek istenen becerinin (süreç bileşeninin) en somut halidir. Eğer sistem önce "öğrencinin fotosentez hızına etki eden faktörleri grafikle ilişkilendirmesi gerekir" kriterini belirlerse, üreteceği soru doğal olarak bir grafik analizi içerecektir.[7]

Türkiye Yüzyılı Maarif Modeli'nin "süreç odaklı değerlendirme" vurgusu, bu tersine mühendislik yaklaşımını desteklemektedir. Modelde, süreç bileşenleri aynı zamanda birer "öğrenme kanıtı" olarak tanımlandığından, otomatik sistemlerin öncelikle bu kanıtları tanımlaması ve soruyu bu kanıtları ortaya çıkaracak bir araç olarak tasarlaması gerekmektedir.[1]

3. Farklı Disiplinlerde Standart Şablonun Korunması: Model Mimarileri ve Metodolojiler

Eğitim sistemi, sayısal (matematik, fizik), sözel (edebiyat, tarih) ve fen (biyoloji, kimya) gibi farklı disiplinleri barındırır. Her disiplinin bilgi yapısı ve değerlendirme mantığı farklı olsa da, merkezi bir değerlendirme sistemi veya geniş ölçekli bir soru bankası yönetimi için standart bir veri şablonunun (Outcome-Instruction-Question-Rubric) korunması elzemdir.

3.1. Disipline Özgü Zorluklar ve Şablon Uyarlaması

- **Sayısal Disiplinler:** Matematik veya fizikte "yönerge" genellikle bir problem durumunu veya veri setini içerir. Rubrik ise çözüm adımlarına (işlem basamaklarına) odaklanır. Burada LLM'lerin en büyük sorunu, işlem hatası yapma (calculation hallucination) riskidir. Bu nedenle, sayısal soru üretiminde sembolik çözücüler (symbolic solvers) veya kod yürütme (code execution) modülleri ile entegre edilmiş mimariler tercih edilmektedir. Şablonun "rubrik" kısmı, işlem adımlarının mantıksal doğruluğunu kontrol eden kurallar dizisine dönüşür.[9]

- **Sözel Disiplinler:** Edebiyat veya tarih sorularında "yönerge" genellikle bir metin parçası veya tarihsel kaynaktır. Rubrik, öğrencinin yorumlama, analiz etme ve argüman geliştirme becerisini ölçer. Burada öznellik riski yüksektir. Modellerin, "anahtar kelime eşleşmesi" yerine "anlamsal benzerlik" ve "argüman tutarlılığı" üzerinden değerlendirme yapacak rubrikler üretmesi gerekir.
- **Fen Disiplinleri (Biyoloji Örneği):** Biyoloji, hem olgusal bilginin hem de süreç becerilerinin (deney tasarlama, veri yorumlama) iç içe geçtiği bir alandır. 10. sınıf biyoloji dersinde "fotosentez hızına etki eden faktörler" konusundaki bir soru, hem grafik okumayı (sayısal beceri) hem de biyolojik süreçleri açıklamayı (sözel beceri) gerektirebilir. Bu nedenle fen disiplinleri, en karmaşık şablon yapısına ihtiyaç duyar. Yönerge genellikle bir deney düzeneği veya biyolojik fenomenin görsel/metin tasviridir.[4]

3.2. Tutarlılığı Sağlayan Mimariler: Komut Ayarlı (Instruction-Tuned) Modeller

Farklı disiplinlerdeki bu varyasyonları tek bir standart şablonda tutabilmek için "Çok Görevli Komut Ayarlama" (Multi-Task Instruction Tuning) mimarileri kullanılmaktadır. Bu mimaride, model tek bir disipline değil, tüm disiplinlerden gelen ve aynı JSON şemasına (Öğrenme Çıktısı -> Yönerge -> Soru -> Rubrik) sadık kalan geniş bir veri setiyle eğitilir.
Bu yaklaşımda, modele verilen "sistem komutu" (system prompt), disiplinden bağımsız olarak yapısal kuralları (örn: "Rubrik her zaman puan toplamı 100 olacak şekilde parçalanmalıdır") dikte ederken, "kullanıcı komutu" (user prompt) disipline özgü içeriği sağlar. Araştırmalar, bu tür "schema-constrained decoding" (şema kısıtlı kod çözme) yöntemlerinin, modelin yaratıcılığını kısıtlamadan yapısal bütünlüğü koruduğunu göstermektedir.[10]
Özellikle Türkiye Yüzyılı Maarif Modeli gibi beceri temelli müfredatlarda, disiplinler arası geçişkenlik (örneğin biyolojideki enerji dönüşümü ile fizikteki enerji korunumunun ilişkilendirilmesi) teşvik edildiğinden, modelin disiplinler arası bağlantıları kurabilecek "Disiplinler Arası Bilgi" (Interdisciplinary Knowledge) katmanına sahip olması gerekmektedir. Bu da modelin eğitim verisinde disiplinlerin izole edilmediği, aksine tematik olarak ilişkilendirildiği bir yapı gerektirir.[1]

4. LLM'lerde Bağlam İçi Öğrenme ve Çok Aşamalı Prompt Tekniklerinin Etkinliği

Büyük Dil Modellerinin (LLM) eğitim materyali üretiminde kullanılması, "Prompt Mühendisliği" (İstem Mühendisliği) disiplininin gelişmesine yol açmıştır. Özellikle "Bağlam İçi Öğrenme" (In-Context Learning - ICL) ve "Zincirleme Düşünce" (Chain-of-Thought - CoT) teknikleri, modelin karmaşık eğitim görevlerini yerine getirmesindeki başarısını kritik düzeyde etkilemektedir.

4.1. Bağlam İçi Öğrenme (In-Context Learning - ICL)

ICL, modelin ağırlıklarını değiştirmeden, istem (prompt) içerisinde verilen örnekler üzerinden görevi öğrenmesini ifade eder. Eğitim materyali üretiminde ICL, modelin istenilen soru

formatını, tonunu ve zorluk seviyesini kavramasında son derece etkilidir.
Örneğin, 10. sınıf biyoloji dersi için "sürdürülebilirlik" temalı bir soru üretilmesi istendiğinde, prompt içine daha önce hazırlanmış, müfredata uygun ve yüksek kaliteli 3 adet soru-rubrik örneği (few-shot prompting) eklenir. Model, bu örneklerdeki örüntüyü (örneğin, sorunun günlük hayatla ilişkilendirilmesi, rubriğin süreç odaklı olması) analiz eder ve dördüncü soruyu bu örüntüye uygun olarak üretir.[12]
Araştırmalar, ICL'in özellikle "stil transferi" konusunda çok başarılı olduğunu göstermektedir. Maarif Modeli'nin kendine has terminolojisi (örn: "süreç bileşeni", "öğrenme kanıtı") ve pedagojik yaklaşımı (örn: "değerler eğitimi"nin soruya yedirilmesi), ICL yoluyla modele hızlıca adapte edilebilir. Model, örneklerdeki "duyarlılık" veya "vatanseverlik" değerlerinin soru köküne nasıl entegre edildiğini görerek benzer üretimler yapabilir.[1]

4.2. Çok Aşamalı Prompt (Chain-of-Thought - CoT) Teknikleri

Eğitim materyali üretimi, tek adımlı bir işlemden ziyade, mantıksal bir akış gerektiren karmaşık bir süreçtir. CoT tekniği, modelin sonuca ulaşmadan önce ara düşünme basamaklarını (intermediate reasoning steps) oluşturmasını sağlar. Bu teknik, özellikle soruların pedagojik derinliğini ve rubriklerin tutarlılığını artırmada kritiktir.
Soru üretiminde CoT akışı şu şekilde kurgulanabilir:

1. **Analiz Adımı:** Modelden önce verilen öğrenme çıktısını (örn: BİY.10.1.1) ve süreç bileşenini (örn: sorgulama) analiz etmesi istenir. "Bu kazanım neyi hedefliyor? Hangi kavram yanılgıları olabilir?"
2. **Senaryo Kurgusu:** "Bu kazanımı günlük hayatta nerede gözlemleriz? (Örn: Kış uykusu, sporcu beslenmesi)."
3. **Soru Taslağı:** Sorunun taslağının oluşturulması.
4. **Rubrik Türetimi:** Sorunun çözüm adımlarının simüle edilmesi ve bu adımlara puan atanması.
5. **Final Çıktı:** Şablonun doldurulması.

Akademik çalışmalar, CoT tekniğinin özellikle matematik ve fen bilimleri gibi mantıksal tutarlılık gerektiren alanlarda, modelin performansını ve çıktı kalitesini önemli ölçüde artırdığını göstermektedir. Ayrıca, "Otomatik CoT" (Auto-CoT) yöntemleri ile modelin kendi düşünme zincirlerini oluşturması sağlanarak, insan müdahalesi olmadan da yüksek kaliteli sorular üretilebilmektedir.[3]
Türkiye Yüzyılı Maarif Modeli bağlamında CoT, modelin "neden" bu soruyu sorduğunu ve "nasıl" değerlendireceğini gerekçelendirmesini sağlar. Bu, üretilen soruların sadece müfredatla uyumlu olmasını değil, aynı zamanda eğitim felsefesiyle de tutarlı olmasını garanti altına alır.

5. Müfredat Standartlarını Entegre Eden Ontoloji ve Kural Tabanlı Hibrit Yaklaşımlar

LLM'lerin en büyük dezavantajı, istatistiksel doğaları gereği "halüsinasyon" görme (gerçek dışı bilgi üretme) ve müfredat sınırlarının dışına çıkma eğilimleridir. Eğitim gibi hataya toleransın çok düşük olduğu bir alanda, bu risklerin minimize edilmesi gerekir. Bu amaçla, LLM'lerin

esnekliğini, Bilgi Grafikleri (Knowledge Graphs - KG) ve Kural Tabanlı Sistemlerin (Rule-Based Systems) kesinliği ile birleştiren hibrit mimariler geliştirilmektedir.

5.1. Ontoloji Tabanlı Müfredat Hizalaması

Bir eğitim ontolojisi, müfredattaki kavramları, kazanımları ve bunlar arasındaki ilişkileri tanımlayan yapılandırılmış bir veri setidir. 10. sınıf biyoloji dersi için oluşturulacak bir ontoloji; "Enerji", "ATP", "Fotosentez", "Solunum" gibi kavramları düğüm (node) olarak; "kapsar", "ön koşuludur", "ilişkilidir" gibi bağları ise kenar (edge) olarak tanımlar. Ayrıca, her kavramın hangi sınıf düzeyinde (9, 10, 11, 12) öğretileceği ve hangi kazanımla (BİY.10.1.X) eşleştiği ontolojide belirtilir.[17]

Otomatik soru üretim sürecinde bu ontoloji bir "kısıtlayıcı" ve "rehber" olarak görev yapar. LLM soru üretirken, ontoloji üzerinde bir yolculuğa (traversal) çıkarılır:

- **Kapsam Kontrolü:** Model, 10. sınıf müfredatında olmayan bir kavramı (örneğin 12. sınıf konusu olan "Oksidatif Fosforilasyonun moleküler detayları") soruya dahil etmek isterse, ontoloji bu kavramın "10. sınıf" düğümüne bağlı olmadığını tespit eder ve işlemi engeller.
- **Kavramsal Derinlik:** Ontoloji, kavramlar arasındaki ilişkileri bildiği için, modeli sadece tanım sormaya değil, kavramlar arası ilişki kurmaya (örn: "Fotosentez ile Solunum arasındaki madde döngüsü ilişkisi") yönlendirir. Bu, Bloom taksonomisinin üst basamaklarına (Analiz, Sentez) hitap eden soruların üretilmesini kolaylaştırır.[20]

5.2. Kural Tabanlı Filtreleme ve Hibrit Mimari

Kural tabanlı sistemler, pedagojik "kırmızı çizgileri" belirler. Türkiye Yüzyılı Maarif Modeli'nde açıkça belirtilen bazı kurallar vardır. Örneğin, biyoloji dersinde bilim insanlarının hayat hikayelerinin ezberletilmemesi, bunun yerine bilime katkılarının ve bilimsel süreçlerin vurgulanması gerektiği belirtilmektedir.[1]

Bir hibrit sistemde, LLM soruyu ürettikten sonra, kural tabanlı bir modül (validator) devreye girer:

- **Kural 1:** Soru metninde biyografik tarih (doğum/ölüm yılı) soruluyor mu? (Evet ise, soruyu reddet).
- **Kural 2:** Rubrikte "süreç bileşeni"ne atıf var mı? (Hayır ise, revize et).
- **Kural 3:** Soru, belirlenen öğrenme çıktısının (BİY.10.1.1) anahtar kelimelerini içeriyor mu?

Bu "Nöro-Sembolik" (Neuro-Symbolic) yaklaşım, LLM'in dilsel yeteneklerini kullanırken, sembolik mantığın (ontoloji ve kurallar) denetim mekanizmasını devreye sokar. Böylece, hem akıcı ve doğal hem de müfredata %100 uyumlu sorular üretilebilir.[22] Özellikle Türk eğitim sistemindeki merkezi sınav ve standartlaşma ihtiyacı düşünüldüğünde, bu hibrit yapı, sistemin güvenilirliği için kritik öneme sahiptir.

6. Pedagojik Geçerlilik ve Rubrik-Soru Tutarlılığı İçin Değerlendirme Sistemleri

Otomatik olarak üretilen soruların sınıfta kullanılabilmesi için pedagojik geçerliliğinin ve teknik kalitesinin denetlenmesi şarttır. Bu denetim, insan uzmanlar tarafından yapılabileceği gibi,

ölçeklenebilirlik açısından yine yapay zeka destekli "LLM-as-a-Judge" (Yargıç olarak LLM) sistemleri ile de gerçekleştirilmektedir.

6.1. Pedagojik Geçerlilik Denetimi

Pedagojik geçerlilik, sorunun ölçmeyi hedeflediği bilişsel seviyeye ve beceriye uygun olup olmadığını ifade eder. Değerlendirme sistemleri şu parametreleri kontrol eder:

- **Bloom Taksonomisi Uyumu:** Üretilen soru, hedeflenen bilişsel seviyeye (örn: Analiz) uygun mu? Bir sınıflandırma modeli (classifier), soru metnini analiz ederek bunun bir "hatırlama" sorusu mu yoksa "değerlendirme" sorusu mu olduğunu tespit eder. Eğer hedef "Analiz" iken soru "Hatırlama" düzeyindeyse, sistem bunu başarısız olarak etiketler.[24]
- **Bağlamsal Uygunluk:** Soru, Maarif Modeli'nin öngördüğü "günlük hayatla ilişkilendirme" kriterini karşılıyor mu? Değerlendirme sistemi, soru metninde gerçek dünya senaryolarının (spor yapan bir insan, fotosentez yapan bir saksı bitkisi vb.) varlığını arar.[1]
- **Dil ve Anlatım:** Sorunun dili, hedef kitlenin (10. sınıf öğrencisi) seviyesine uygun mu? Karmaşık cümle yapıları veya müfredat dışı terminoloji kullanımı kontrol edilir.

6.2. Rubrik-Soru Tutarlılığı (Alignment)

En sık karşılaşılan sorunlardan biri, sorunun istediği yanıt ile rubriğin puanladığı kriterlerin uyuşmamasıdır. Örneğin, soru "X ve Y arasındaki üç farkı yazınız" derken, rubrik sadece iki farka puan veriyorsa veya soru "açıklayınız" derken rubrik sadece "listeleme" bekliyorsa, ciddi bir tutarsızlık vardır.

Bu tutarlılığı denetlemek için **Tutarlılık Analizi (Consistency Checking)** algoritmaları kullanılır:

- **Semantik Benzerlik:** Soru kökündeki eylem fiilleri (açıkla, listele, karşılaştır) ile rubrikteki kriterlerin semantik uyumu ölçülür.
- **Çözülebilirlik Testi (Solvability Check):** Sistemin içinde bir "Öğrenci Ajanı" (Student Agent) oluşturulur. Bu ajan, sadece soru metnini kullanarak bir yanıt üretir. Daha sonra bir "Öğretmen Ajanı" (Teacher Agent), üretilen rubriği kullanarak bu yanıtı puanlar. Eğer ajan, doğru bilgi verdiği halde rubrikten düşük puan alıyorsa veya tam tersi durum söz konusuysa, rubrik-soru uyumsuzluğu raporlanır.[26]

Bu otomatik denetim mekanizmaları, üretilen soruların "ham" halden "kullanıma hazır" hale gelmesini sağlayan kalite kontrol kapılarıdır (Quality Gates).

7. RAG ve İnce Ayar (Fine-Tuning) Yöntemlerinin Karşılaştırılması

Otomatik soru üretiminde kullanılan iki temel strateji olan "Bilgi Geri Getirme Destekli Nesil" (Retrieval-Augmented Generation - RAG) ve "İnce Ayar" (Fine-Tuning), belirli bir akademik formata sadık kalma konusunda farklı avantaj ve dezavantajlara sahiptir.

7.1. İnce Ayar (Fine-Tuning) Yöntemi

İnce ayar, önceden eğitilmiş bir modelin (base model), belirli bir görev için hazırlanmış özel bir veri seti ile yeniden eğitilmesidir.

- **Avantajları:** İnce ayar, modelin "davranışını" ve "formatını" öğrenmesinde çok etkilidir. Örneğin, modelin sürekli olarak JSON formatında çıktı vermesi, belirli bir akademik dili (Türkçe eğitim terminolojisi) kullanması ve rubrikleri belirli bir puanlama mantığıyla (örn: 10-10-10 puan dağılımı) oluşturması isteniyorsa, ince ayar en iyi çözümdür. Model, eğitim verisindeki şablonları "içselleştirir".[29]
- **Dezavantajları:** İnce ayar, "bilgi" öğretmek için ideal değildir. Model, eğitim verisindeki bilgileri ezberleyebilir ancak müfredat değiştiğinde veya yeni bir konu eklendiğinde modelin yeniden eğitilmesi gerekir. Ayrıca, modelin halüsinasyon görme riski devam eder.

7.2. RAG (Retrieval-Augmented Generation) Yöntemi

RAG, modelin üretim yaparken harici bir bilgi tabanından (ders kitapları, müfredat dosyaları) anlık olarak bilgi çekmesidir.

- **Avantajları:** RAG, "doğruluk" ve "güncellik" konusunda üstündür. Model, soruyu kafasından uydurmak yerine, doğrudan 10. sınıf biyoloji kitabının ilgili sayfasındaki metne dayanarak oluşturur. Bu, müfredat dışı bilgi riskini ve halüsinasyonları minimize eder. Ayrıca kaynak gösterimi (citation) yapılabilir.[29]
- **Dezavantajları:** RAG, modelin format ve stil tutarlılığını garanti etmez. Eğer base model talimatları tam anlamazsa, doğru bilgiyi yanlış formatta (örn: rubrik olmadan) sunabilir.

7.3. Karşılaştırmalı Başarı ve Hibrit Yaklaşım (RAFT)

Akademik çalışmalar, RAG ve Fine-Tuning'in birbirinin alternatifi değil, tamamlayıcısı olduğunu göstermektedir. **RAFT (Retrieval-Augmented Fine-Tuning)** adı verilen hibrit yaklaşım, her iki yöntemin güçlü yönlerini birleştirir.

- **Yöntem:** Model, soru üretme *görevi* ve *formatı* üzerine (rubrik yapısı, Bloom taksonomisi dili vb.) ince ayar yapılır. Ancak, sorunun *içeriği* (biyolojik gerçekler) RAG üzerinden sağlanır.
- **Sonuç:** Yapılan kıyaslamalar, RAFT yaklaşımının, sadece RAG veya sadece Fine-Tuning kullanan sistemlere göre hem format sadakati hem de içerik doğruluğu açısından en yüksek başarı oranını yakaladığını göstermektedir.[29] Türkiye Yüzyılı Maarif Modeli gibi hem formatın (süreç bileşenleri) hem de içeriğin (müfredat) kritik olduğu bir senaryoda, RAFT mimarisi en uygun çözümdür.

8. Veri Seti Oluşturma, Etiketleme ve Taksonomi Eşleştirme Zorlukları

Disiplinler arası genel bir soru üretim motoru geliştirmenin en büyük darboğazı, modeli eğitecek ve test edecek nitelikli veri setlerinin eksikliğidir. Özellikle Türkçe eğitim verisi ve Maarif Modeli'ne özgü etiketlemeler konusunda ciddi boşluklar bulunmaktadır.

8.1. Veri Seti Oluşturma Zorlukları

- **Veri Kıtlığı:** İngilizce için SQuAD, RACE gibi büyük soru-cevap veri setleri bulunurken, Türkçe için ve özellikle açık uçlu, rubrikli, müfredat uyumlu soru setleri son derece kısıtlıdır. Mevcut veriler genellikle çoktan seçmeli testlerden oluşmaktadır.[33]
- **Sentetik Veri Üretimi:** Bu sorunu aşmak için "Sentetik Veri Üretimi" (Synthetic Data Generation) yöntemi kullanılmaktadır. GPT-4 gibi güçlü modeller kullanılarak, uzman öğretmenlerin gözetiminde "altın standart" (gold standard) örnekler oluşturulur. Bu sentetik veriler, daha küçük ve hızlı modelleri (Llama 3, Mistral) eğitmek için kullanılır.[34]

8.2. Etiketleme ve Taksonomi Eşleştirme

- **Bloom Taksonomisi Eşleşmesi:** Soruların Bloom taksonomisindeki (Hatırlama, Anlama, Uygulama, Analiz, Değerlendirme, Yaratma) yerine göre etiketlenmesi sübjektif bir süreçtir. Bir uzmana göre "Analiz" olan soru, diğerine göre "Uygulama" olabilir. Bu gürültülü veri, modelin performansını düşürür. Çözüm olarak, çoklu etiketleme ve uzmanlar arası mutabakat (inter-rater agreement) süreçleri işletilmelidir.[24]
- **Süreç Bileşenleri Eşleşmesi:** Maarif Modeli'nin getirdiği "Süreç Bileşenleri" (örn: KB2.14 Yorumlama), standart taksonomilerden farklıdır. Bu yeni terminolojinin modele öğretilmesi için, müfredat dokümanlarından ve örnek sorulardan oluşan özel bir "eşleştirme veri seti" (alignment dataset) oluşturulmalıdır. Örneğin, "Tahmin Etme" becerisinin "Bilimsel Gözleme Dayalı Tahmin" ve "Mevcut Veriye Dayalı Tahmin" olarak ayrıştığı durumların modele tanıtılması gerekir.[1]

9. Genel Sistem Mimarisi Önerisi: "Maarif-Gen"

Elde edilen bulgular ve analizler ışığında, Türkiye Yüzyılı Maarif Modeli'nin ihtiyaçlarına tam olarak cevap verebilecek, disiplinler arası ve ölçeklenebilir bir otomatik soru üretim sistemi için **"Maarif-Gen"** mimarisini öneriyoruz.

9.1. Sistem Mimarisi Bileşenleri

Sistem, **İnsan Döngülü Nöro-Sembolik (Human-in-the-Loop Neuro-Symbolic)** bir yapıya sahiptir.

1. **Müfredat Bilgi Grafiği (Curriculum Knowledge Graph - CKG):**
    - Sistemin "hafızası" ve "mantık katmanı"dır. Ders kitapları, öğretim programları ve kazanım tabloları dijitalleştirilerek bir Neo4j graf veritabanına işlenir.
    - Düğümler: Dersler, Üniteler, Kazanımlar, Kavramlar, Süreç Bileşenleri.
    - İlişkiler: "Kapsar", "Gerektirir", "Ön koşuludur", "İlişkilidir".
2. **RAG Motoru (Retrieval Engine):**
    - Öğretmen bir kazanım seçtiğinde (örn: BİY.10.1.1), sistem CKG üzerinden ilgili ders kitabı metinlerini, kavram haritalarını ve benzer çıkmış soru örneklerini vektör veritabanından (ChromaDB veya Milvus) çeker.
3. **RAFT Tabanlı Üretim Modeli (Generation Core):**
    - İnce ayar yapılmış (Fine-Tuned) bir LLM (örn: Türkçe için optimize edilmiş Llama-3 türevi), RAG'den gelen içerik ve CKG'den gelen yapısal kısıtlarla beslenir.
    - Model, **Zincirleme Düşünce (CoT)** tekniği ile önce sorunun pedagojik kurgusunu

planlar, sonra soruyu yazar, en son rubriği oluşturur.

4. **Pedagojik Denetleyici (Validator Agent):**
    - Üretilen soru ve rubrik, ayrı bir "Yargıç Model" (Judge LLM) tarafından denetlenir. Bloom seviyesi, müfredat uyumu, dil kalitesi ve rubrik tutarlılığı puanlanır. Eşik değerin altındaki sorular otomatik olarak yeniden üretilir (Self-Correction).[26]
5. **Öğretmen Arayüzü ve Geri Bildirim Döngüsü:**
    - Öğretmen, üretilen soruyu görür, düzenler veya onaylar. Öğretmenin yaptığı her düzenleme (örneğin rubrik puanını değiştirmesi), sistemi iyileştirmek için bir "geri bildirim sinyali" (RLHF) olarak kaydedilir.

9.2. Teknolojik Gereksinimler

- **Veri Altyapısı:** Yüksek performanslı Vektör ve Graf veritabanları entegrasyonu.
- **İşlem Gücü:** Fine-Tuning ve gerçek zamanlı üretim (Inference) için GPU kümeleri.
- **NLP Araçları:** Türkçe için özelleştirilmiş morfolojik analizörler ve gömme (embedding) modelleri.
- **Güvenlik:** Öğrenci verisi ve telifli içeriklerin (ders kitapları) güvenliği için yerel sunucularda (On-Premise) veya özel bulut alanlarında çalışan modeller.

9.3. Uygulama Stratejileri

1. **Pilot Uygulama:** Sistemin, veri yapısı en uygun olan 10. Sınıf Biyoloji dersi ile pilot olarak başlatılması. Bu dersteki "süreç bileşenleri"nin netliği, modelin başarısını ölçmeyi kolaylaştıracaktır.
2. **Uzman Etiketlemesi:** Maarif Modeli'ne hakim öğretmenlerden oluşan bir ekibin, modelin ilk eğitimi için "Altın Veri Seti" (Golden Dataset) oluşturması.
3. **Kademeli Yaygınlaştırma:** Sistemin önce sayısal (Fizik, Kimya), sonra sözel (Tarih, Coğrafya) derslere, ontolojilerin genişletilmesi suretiyle yaygınlaştırılması.
4. **Eğitmen Eğitimi:** Öğretmenlerin sistemi bir "soru bankası" değil, bir "üretim asistanı" olarak görmelerini sağlayacak eğitimlerin verilmesi.

10. Sonuç

Türkiye Yüzyılı Maarif Modeli'nin vizyonu, öğrencileri sadece bilen değil, bilgiyi kullanan, sorgulayan ve üreten bireyler olarak yetiştirmektir. Bu vizyonun ölçme ve değerlendirme ayağında hayata geçirilmesi, geleneksel yöntemlerle sürdürülebilir değildir. Önerilen **Maarif-Gen** mimarisi; ontoloji destekli RAG, ince ayar ve zincirleme düşünce tekniklerinin hibrit bir kullanımıyla, müfredatla tam uyumlu, pedagojik olarak geçerli ve süreç odaklı açık uçlu soruların ölçeklenebilir şekilde üretilmesini mümkün kılacaktır. Bu teknolojik dönüşüm, öğretmenlerin üzerindeki operasyonel yükü alarak, onların asıl işlevi olan öğrencilere rehberlik etme ve nitelikli geri bildirim verme süreçlerine odaklanmalarını sağlayacaktır. Bu sistem, Türk eğitim teknolojileri ekosistemi için sadece bir araç değil, stratejik bir altyapı yatırımı niteliğindedir.

Alıntılanan çalışmalar

1. TYMM Maarif Modeli Yaklaşımı_compressed.pdf
2. ChatGPT as a Stable and Fair Tool for Automated Essay Scoring - MDPI, erişim tarihi Ocak 11, 2026, https://www.mdpi.com/2227-7102/15/8/946
3. A Chain-of-Thought Prompting Approach with LLMs for Evaluating Students' Formative Assessment Responses in Science - AAAI Publications, erişim tarihi Ocak 11, 2026, https://ojs.aaai.org/index.php/AAAI/article/view/30364/32416
4. Instructional Goal-Aligned Question Generation for Student Evaluation in Virtual Lab Settings: How Closely Do LLMs Actually Align? - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2510.06411v1
5. From Experts to LLMs: Evaluating the Quality of Automatically Generated Ontologies - CEUR-WS.org, erişim tarihi Ocak 11, 2026, https://ceur-ws.org/Vol-3977/elmke-1.pdf
6. QuRL: Rubrics As Judge For Open-Ended Question Answering - OpenReview, erişim tarihi Ocak 11, 2026, https://openreview.net/forum?id=DrhWTuhtYq
7. Rubric development for AI-enabled scoring of three-dimensional constructed-response assessment aligned to NGSS learning progression - Frontiers, erişim tarihi Ocak 11, 2026, https://www.frontiersin.org/journals/education/articles/10.3389/feduc.2022.983055/full
8. RubricEval: A Scalable Human-LLM Evaluation Framework for Open-Ended Tasks - Stanford University, erişim tarihi Ocak 11, 2026, https://web.stanford.edu/class/cs224n/final-reports/256846781.pdf
9. Scalable and Explainable Automated Scoring for Open-Ended Constructed Response Math Word Problems - ACL Anthology, erişim tarihi Ocak 11, 2026, https://aclanthology.org/2023.bea-1.12.pdf
10. Large Language Models: A Structured Taxonomy and Review of Challenges, Limitations, Solutions, and Future Directions - MDPI, erişim tarihi Ocak 11, 2026, https://www.mdpi.com/2076-3417/15/14/8103
11. Information Retrieval System for Automating Quiz Generation and Evaluation Using Large Language Models - Cureus Journals, erişim tarihi Ocak 11, 2026, https://www.cureusjournals.com/articles/5957-information-retrieval-system-for-automating-quiz-generation-and-evaluation-using-large-language-models.pdf
12. Harnessing the Power of In-Context Learning and Chain-of-Thought Prompting for Enhanced Language Model Interactions | by Abraham Chengshuai Yang | Medium, erişim tarihi Ocak 11, 2026, https://medium.com/@platformai/harnessing-the-power-of-in-context-learning-and-chain-of-thought-prompting-for-enhanced-language-bc0c4c3018ca
13. Pre-training vs Fine-Tuning vs In-Context Learning of Large Language Models, erişim tarihi Ocak 11, 2026, https://www.entrypointai.com/blog/pre-training-vs-fine-tuning-vs-in-context-learning-of-large-language-models/
14. Fine-Tuning vs. In-Context Learning: A Practical Guide | by Hey Amit - Medium, erişim tarihi Ocak 11, 2026,

https://medium.com/@heyamit10/fine-tuning-vs-in-context-learning-a-practical-guide-08163ede6d1a
15. What is chain of thought (CoT) prompting? - IBM, erişim tarihi Ocak 11, 2026, https://www.ibm.com/think/topics/chain-of-thoughts
16. Automatic Chain of Thought Prompting in Large Language Models - OpenReview, erişim tarihi Ocak 11, 2026, https://openreview.net/forum?id=5NTt8GFjUHkr
17. Multiple Choice Question Generation Utilizing An Ontology, erişim tarihi Ocak 11, 2026, https://people.ischool.berkeley.edu/~hearst/papers/BEA_2017.pdf
18. Optimizing Automated Question Generation for Educational Assessments: A Semantic Analysis of LLMs with Structured and Unstructured Ontologies | Engineering, Technology & Applied Science Research, erişim tarihi Ocak 11, 2026, https://etasr.com/index.php/ETASR/article/view/10662
19. LLM-supported collaborative ontology design for data and knowledge management platforms - PubMed Central, erişim tarihi Ocak 11, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC12646930/
20. Optimizing Automated Question Generation for Educational Assessments: A Semantic Analysis of LLMs with Structured and Unstructured Ontologies - ResearchGate, erişim tarihi Ocak 11, 2026, https://www.researchgate.net/publication/397706797_Optimizing_Automated_Question_Generation_for_Educational_Assessments_A_Semantic_Analysis_of_LLMs_with_Structured_and_Unstructured_Ontologies
21. An Architecture for Generating Questions, Answers, and Feedback from Ontologies, erişim tarihi Ocak 11, 2026, https://www.researchgate.net/publication/373030035_An_Architecture_for_Generating_Questions_Answers_and_Feedback_from_Ontologies
22. HyDRA: A Hybrid-Driven Reasoning Architecture for Verifiable Knowledge Graphs - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2507.15917v1
23. AI Reasoning in Deep Learning Era: From Symbolic AI to Neural–Symbolic AI - MDPI, erişim tarihi Ocak 11, 2026, https://www.mdpi.com/2227-7390/13/11/1707
24. Revolutionising Educational Assessment: Automated Question Classification using Bloom's Taxonomy and Deep Learning Techniques - ERIC, erişim tarihi Ocak 11, 2026, https://files.eric.ed.gov/fulltext/EJ1413430.pdf
25. [2504.14232] Assessing AI-Generated Questions' Alignment with Cognitive Frameworks in Educational Assessment - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/abs/2504.14232
26. Automated Consistency Analysis of LLMs - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2502.07036v1
27. Multi-Step Grading Rubrics with LLMs for Answer Evaluation - The Green Report, erişim tarihi Ocak 11, 2026, https://www.thegreenreport.blog/articles/multi-step-grading-rubrics-with-llms-for-answer-evaluation/multi-step-grading-rubrics-with-llms-for-answer-evaluation.html
28. Auto-Rubric: Learning to Extract Generalizable Criteria for Reward Modeling - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2510.17314v1
29. RAG vs. Fine-Tuning: How to Choose - Oracle, erişim tarihi Ocak 11, 2026,

https://www.oracle.com/artificial-intelligence/generative-ai/retrieval-augmented-generation-rag/rag-fine-tuning/
30. Fine-tuning LLMs: overview and guide | Google Cloud, erişim tarihi Ocak 11, 2026, https://cloud.google.com/use-cases/fine-tuning-ai-models
31. What is Retrieval-Augmented Generation (RAG)? - Google Cloud, erişim tarihi Ocak 11, 2026, https://cloud.google.com/use-cases/retrieval-augmented-generation
32. Fine Tuning vs. Retrieval Augmented Generation for Less Popular Knowledge - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2403.01432v2
33. BloomLLM: Large Language Models Based Question Generation Combining Supervised Fine-Tuning and Bloom's Taxonomy, erişim tarihi Ocak 11, 2026, https://www.dfki.de/fileadmin/user_upload/import/15289_978-3-031-72312-4_11.pdf
34. Opportunities and Challenges of LLMs in Education: An NLP Perspective - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/html/2507.22753v1
35. Probing Internal Assumptions of the Revised Bloom's Taxonomy - PMC - NIH, erişim tarihi Ocak 11, 2026, https://pmc.ncbi.nlm.nih.gov/articles/PMC9727608/
36. [2410.12893] MIRROR: A Novel Approach for the Automated Evaluation of Open-Ended Question Generation - arXiv, erişim tarihi Ocak 11, 2026, https://arxiv.org/abs/2410.12893